

Klasifikasi Tumor Otak Menggunakan Metode Deep Learning CNN

Disusun Oleh

Kelompok 1:

Justin Stephen (72126)

Nurfajriah Oktaviani (68637)

Geraldo Nathanael (55213)



Abstrak

Tumor otak merupakan penyakit yang mempengaruhi sistem saraf pusat dan memiliki dampak signifikan terhadap kesehatan dan kualitas hidup pasien. Penelitian ini bertujuan untuk meningkatkan klasifikasi tumor otak menggunakan teknologi Deep Learning, khususnya Convolutional Neural Networks (CNN). Metode ini memanfaatkan dataset citra MRI otak dari tiga jenis tumor utama: meningioma, glioma, dan tumor pituitari. Pra-pemrosesan data dilakukan dengan mengonversi citra menjadi grayscale, resizing, dan penerapan filter untuk mengurangi noise. Selanjutnya, model CNN dikembangkan dan dievaluasi menggunakan matrix kinerja seperti akurasi, presisi, recall, dan F1-score. Hasil penelitian menunjukkan bahwa model CNN mampu membedakan antara jenis-jenis tumor otak dengan sensitivitas dan spesifisitas yang tinggi. Kesimpulannya, teknologi Deep Learning terutama CNN, memiliki potensi besar dalam meningkatkan diagnosis tumor otak, membuka jalan bagi perawatan yang lebih efektif dan personalisasi.

Kata kunci: Tumor otak, Deep Learning, Convolutional Neural Networks, klasifikasi, citra medis

BAB 1

PENDAHULUAN



Latar Belakang

Penelitian tentang tumor otak penting untuk meningkatkan diagnosis dan pengobatan. Studi oleh Cheng et al. menggunakan pemrosesan citra untuk memperbaiki klasifikasi tumor. Namun, perlu pengembangan lebih lanjut, terutama dengan memanfaatkan teknologi Deep Learning seperti Convolutional Neural Networks (CNN). CNN dapat secara otomatis mengekstrak fitur penting dari data citra, meningkatkan akurasi klasifikasi. Penelitian oleh Litjens et al. dan Shen et al. menunjukkan potensi besar CNN dalam meningkatkan diagnosis tumor otak, dengan sensitivitas dan spesifisitas yang lebih baik daripada metode tradisional. Dengan penelitian ini, diharapkan pengembangan teknik diagnostik yang lebih baik dan perawatan yang lebih efektif dapat ditemukan untuk pasien tumor otak, serta memperluas aplikasi CNN dalam bidang medis.

Perumusan Masalah

1. Bagaimana meningkatkan kinerja klasifikasi tumor otak melalui penggunaan teknologi pemrosesan citra dan analisis data yang canggih?
2. Bagaimana mengoptimalkan teknik pengambilan tumor otak untuk meningkatkan akurasi diagnosis?

Batasan Masalah

1. Penelitian ini akan fokus pada klasifikasi tiga jenis tumor otak utama: meningioma, glioma, dan tumor pituitari.
2. Analisis akan terbatas pada data citra otak dengan pemberat kontras T1 pada pemindaian.
3. Aspek klinis dan genetik yang mendalam tidak akan dibahas secara rinci dalam penelitian ini.

Tujuan Penelitian

- Mengembangkan model klasifikasi tumor otak yang mampu membedakan dengan akurat antara meningioma, glioma, dan tumor pituitari.
- Mengevaluasi dan menyempurnakan proses ekstraksi fitur dan teknik pemrosesan citra dalam model CNN untuk meningkatkan akurasi diagnosis tumor otak, diukur melalui metrik kinerja seperti akurasi, presisi, recall, dan F1-score.
- Menilai efektivitas metode yang dikembangkan melalui penggunaan dataset yang signifikan dalam meningkatkan presisi diagnosis tumor otak.

Manfaat Penelitian

1. Memberikan landasan untuk pengembangan metode diagnostik yang lebih akurat dan efektif dalam klasifikasi jenis-jenis tumor otak.
2. Meningkatkan kemungkinan diagnosis dini tumor otak, memungkinkan perawatan yang lebih cepat dan tepat waktu.
3. Memberikan kontribusi pada kemajuan bidang kedokteran dengan membuka jalan bagi pengembangan strategi perawatan yang lebih efektif bagi pasien tumor otak.

BAB II

LANDASAN TEORI

Konsep Dasar dan Aplikasi Deep Learning dalam Medis

Deep Learning merupakan cabang dari machine learning yang memanfaatkan jaringan saraf tiruan untuk memproses data dengan kompleksitas tinggi. Dalam kedokteran, Deep Learning terutama digunakan untuk menganalisis citra medis. Teknologi ini telah membuka peluang baru dalam identifikasi, klasifikasi, dan segmentasi tumor, yang memperbaiki diagnosis dan perencanaan perawatan pasien. Keunggulan utamanya adalah kemampuannya untuk mengekstrak fitur relevan secara otomatis dari citra medis tanpa perlu ekstraksi manual yang subjektif. Penelitian oleh Litjens et al. (2017) menunjukkan potensi Deep Learning dalam meningkatkan akurasi diagnosis berbagai kondisi medis melalui analisis citra, sementara studi oleh Shen et al. (2019) menyoroti peran penting Convolutional Neural Networks (CNN) dalam deteksi dan klasifikasi tumor otak dengan peningkatan sensitivitas dan spesifisitas yang signifikan dibandingkan dengan metode tradisional.

Model Convolutional Neural Networks (CNN)

- Lapisan Input
- Lapisan Konvolusi

$$G(x, y) = \sum_{i=-a}^a \sum_{j=-b}^b F(i, j) \cdot I(x - i, y - j)$$

- Lapisan Pooling

$$P(x, y) = \max_{(i, j) \in W_{x, y}} I(i, j)$$

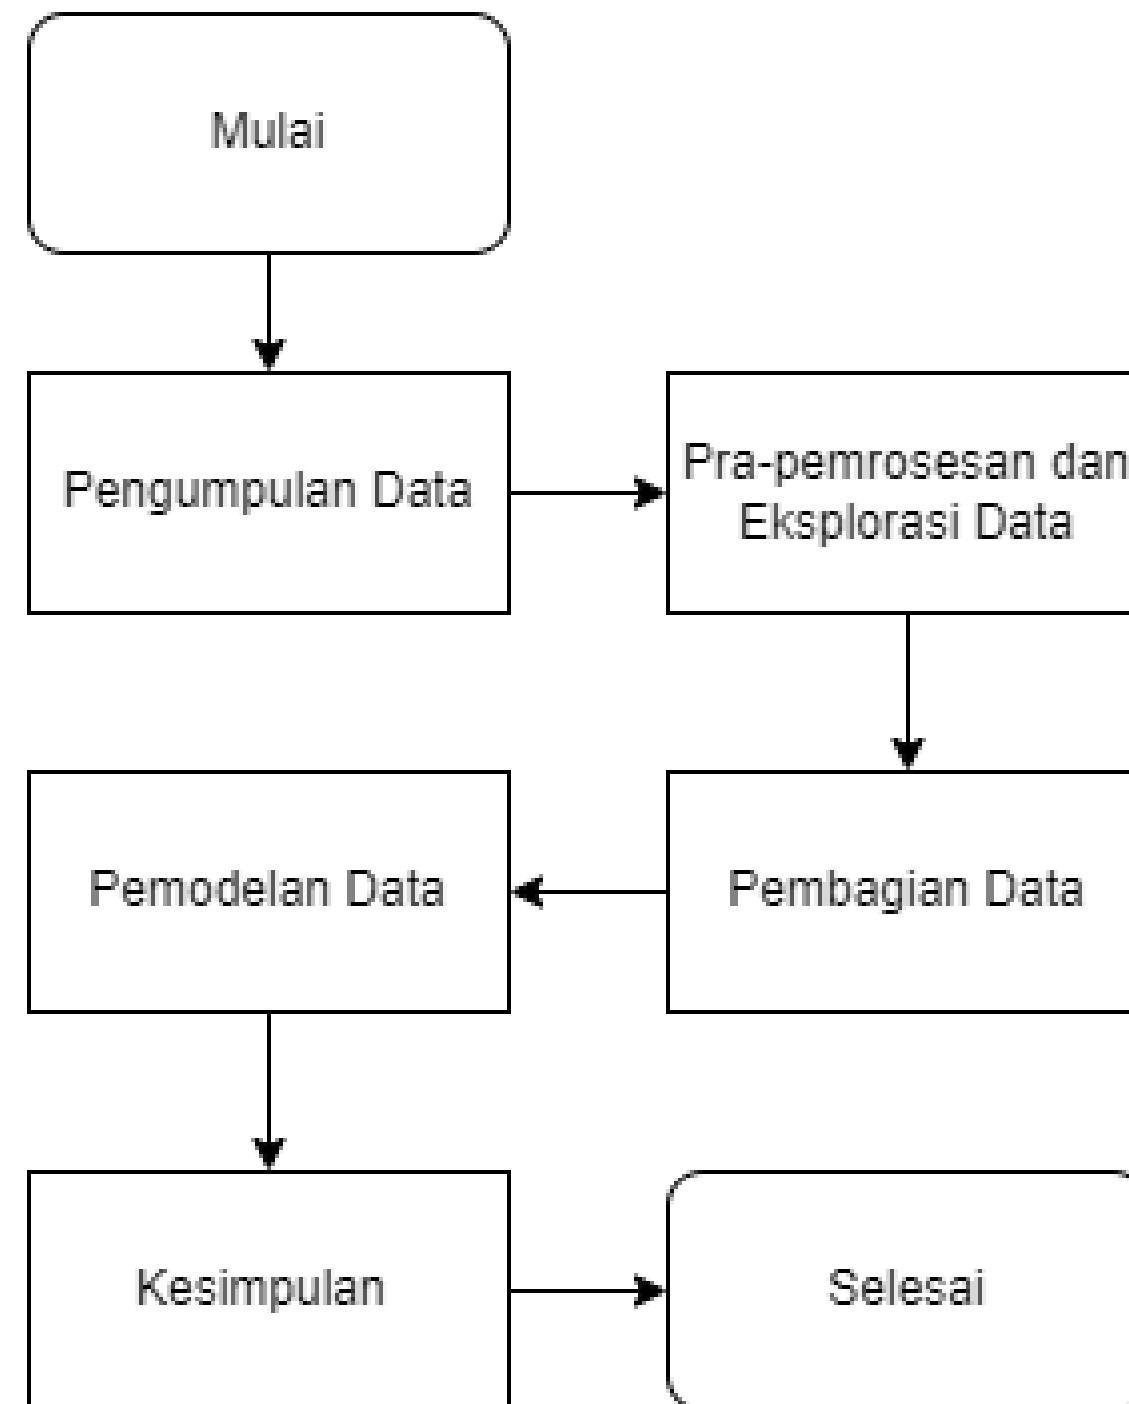
- Lapisan Fully Connected (FC)

$$O_k = \sigma \left(\sum_{n=1}^N w_{k, n} \cdot x_n + b_k \right)$$

BAB III

METODOLOGI PENELITIAN





Gambaran Umum Dataset Penelitian

Dataset yang digunakan dalam penelitian ini adalah Brain Tumor Image Dataset yang mencakup sampel dari tiga jenis tumor otak, yaitu meningioma, glioma, dan tumor pituitari. Dataset ini terdiri dari gambar-gambar berformat ".png" yang telah dikonversi dari format ".mat". Asal dataset ini berasal dari berkas asli yang dibagikan oleh

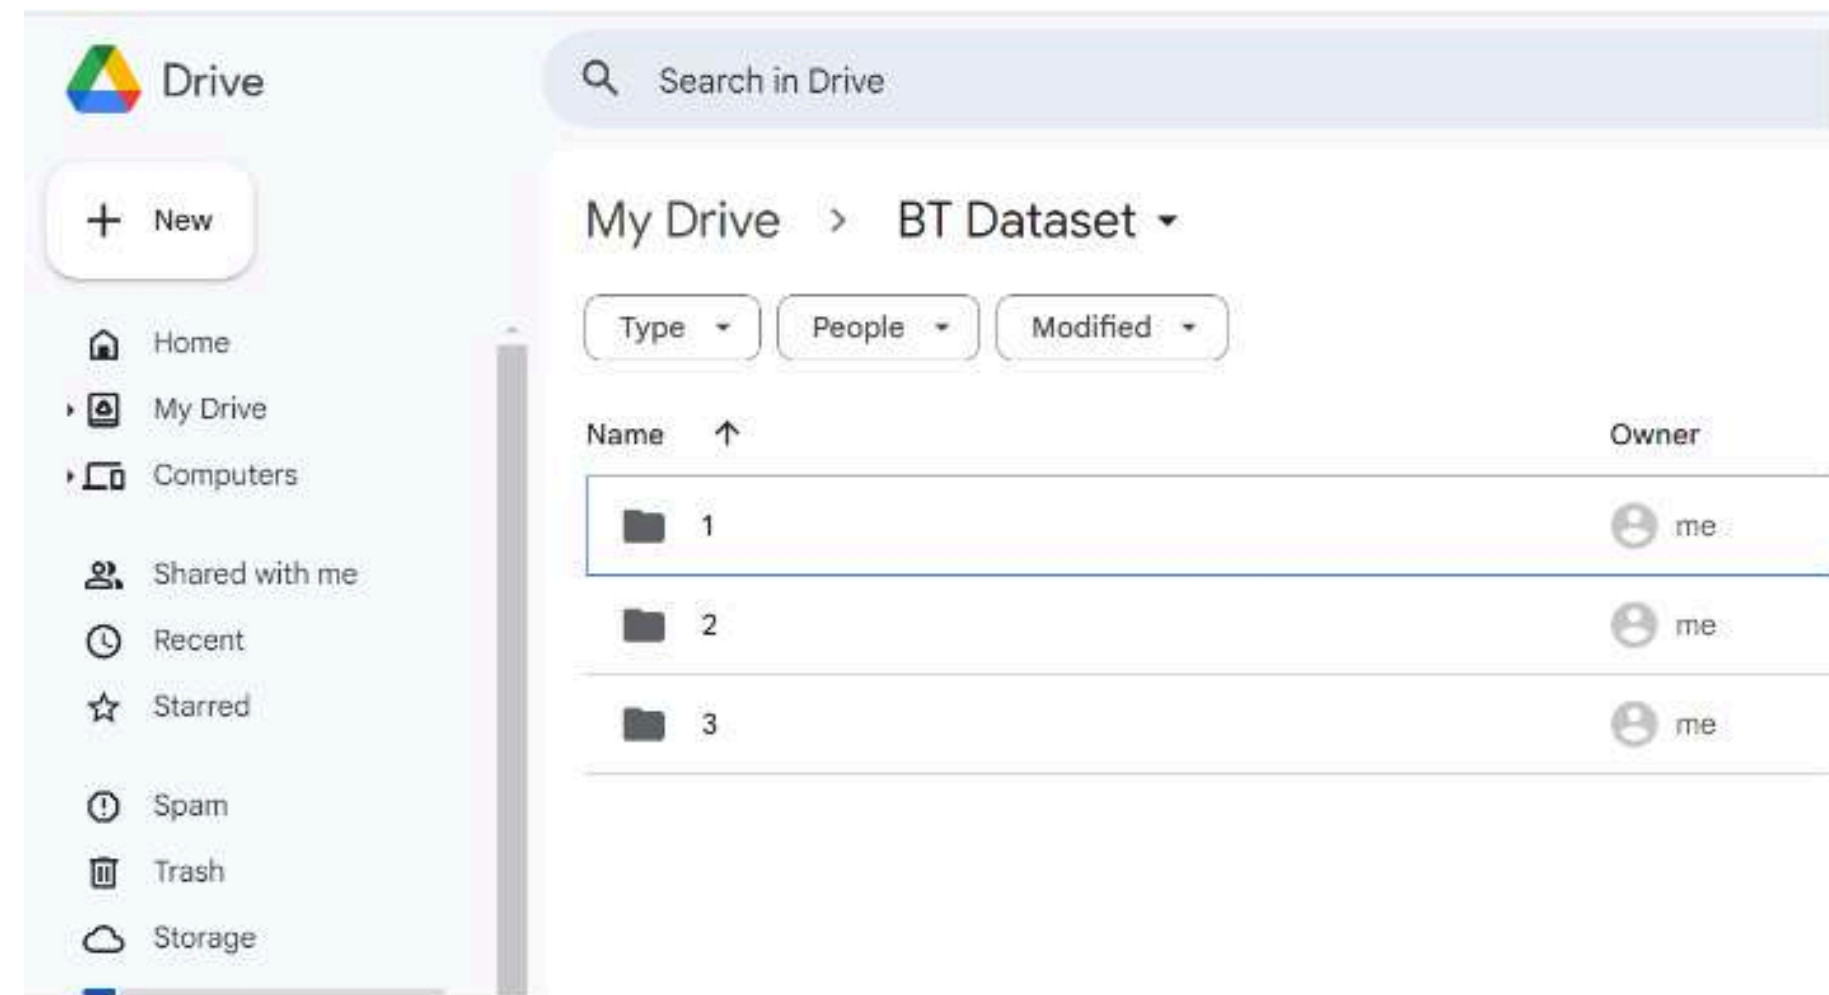
Cheng, Jun (2017): brain tumor dataset. figshare. Dataset.

<https://doi.org/10.6084/m9.figshare.1512427.v5>


Dataset ini terdiri dari 3064 gambar T1-weighted contrast-enhanced yang berasal dari 233 pasien dengan tiga jenis tumor otak: meningioma (708 gambar), glioma (1426 gambar), dan tumor pituitari (930 gambar).

Eksplorasi dan Pra-pemrosesan Data


Sebelum dilakukan eksplorasi dan pra-pemrosesan data, pengumpulan data dilakukan terlebih dahulu karena tahap ini merupakan langkah awal dalam proyek ini. Data yang digunakan berasal dari kumpulan dataset citra MRI otak yang tersimpan di Google Drive, mencakup berbagai jenis tumor otak seperti glioma, meningioma, dan pituitary. Dengan menggunakan library Python, data ini diakses dan siap untuk diproses lebih lanjut. Pengaturan lokasi folder dataset dan memuat gambar dari setiap kategori tumor merupakan langkah awal untuk mempersiapkan dataset untuk analisis lebih lanjut.



Setelah data terkumpul, eksplorasi dan pra-pemrosesan data dilakukan secara bersamaan untuk mempersiapkan dataset untuk pemodelan. Eksplorasi data melibatkan penggunaan fungsi `load_images_from_folder`, yang membaca citra dari folder yang berbeda berdasarkan jenis tumor, mengumpulkan citra serta label terkait, dan visualisasi distribusi data dengan memplot jumlah gambar untuk setiap kategori tumor.



Selanjutnya, langkah pra-pemrosesan melibatkan konversi gambar menjadi grayscale untuk mengurangi kompleksitas dan dimensi data, resizing gambar menjadi ukuran yang seragam (128x128) untuk konsistensi input model, dan penerapan filter Gaussian Blur dan Median Blur untuk mengurangi noise. Proses ini menggunakan library cv2 dari OpenCV dan normalisasi nilai piksel dengan membaginya dengan 255, mengonversi data menjadi rentang 0-1, praktik umum dalam pra-pemrosesan data untuk model deep learning. Visualisasi perbandingan antara citra asli, setelah diterapkan low-pass filtered, dan median filtered memberikan wawasan tentang efek pra-pemrosesan pada kualitas citra.



Rekayasa Fitur

Teknik pemrosesan citra memainkan peran krusial dalam diagnosa tumor otak, mengubah citra medis menjadi sumber data yang kaya untuk analisis. Proses dimulai dengan pra pemrosesan citra, yang mencakup peningkatan kontras, normalisasi, dan reduksi noise untuk memperjelas fitur citra. Selanjutnya, ekstraksi fitur otomatis dilakukan untuk mengidentifikasi atribut penting seperti tekstur, bentuk, dan intensitas, menandakan keberadaan tumor. Segmentasi citra adalah langkah penting berikutnya, memisahkan area tumor dari jaringan otak normal dengan akurasi tinggi untuk menentukan ukuran, lokasi, dan karakteristik tumor. Penggunaan Convolutional Neural Networks (CNN) telah terbukti efektif dalam semua aspek pemrosesan citra ini, memberikan dukungan yang kuat untuk keputusan klinis dengan data yang objektif dan akurat.



Pembagian Data

Dengan dataset yang telah diproses, langkah selanjutnya adalah membagi dataset menjadi set pelatihan dan pengujian menggunakan fungsi `train_test_split` dari library `sklearn`. Pembagian ini dengan proporsi 80% untuk pelatihan dan 20% untuk pengujian memastikan bahwa model dilatih pada sebagian besar data, dan juga memiliki set data independen untuk evaluasi performa.



Pemodelan dengan CNN

Pemodelan dilakukan dengan menggunakan Convolutional Neural Network (CNN), yang merupakan pilihan yang tepat untuk pengolahan citra karena kemampuannya dalam mengekstrak fitur citra secara hierarkis. Model CNN dibangun dengan beberapa lapisan konvolusi dan pooling, diikuti dengan lapisan dense untuk klasifikasi. Arsitektur ini dikompilasi dengan optimizer Adam dan loss function categorical_crossentropy untuk menangani masalah klasifikasi multi-kelas.

```
# Modelling CNN

input_shape = (128, 128, 1)

model = models.Sequential([
    layers.Conv2D(32, (3, 3), activation='relu', input_shape=input_shape),
    layers.MaxPooling2D((2, 2)),
    layers.Conv2D(64, (3, 3), activation='relu'),
    layers.MaxPooling2D((2, 2)),
    layers.Flatten(),
    layers.Dense(64, activation='relu'),
    layers.Dense(len(tumor_types), activation='softmax')
])

model.compile(optimizer='adam', loss='categorical_crossentropy', metrics=['accuracy'])
```

```
# Convert Label dengan one hot encoder

label_encoder = LabelEncoder()
train_labels_encoded = label_encoder.fit_transform(train_labels)
test_labels_encoded = label_encoder.transform(test_labels)

train_labels_one_hot = to_categorical(train_labels_encoded)
test_labels_one_hot = to_categorical(test_labels_encoded)
```




Pelatihan dan Evaluasi Model

Model dilatih dengan set pelatihan menggunakan matrix akurasi. Proses pelatihan juga melibatkan validasi dengan subset dari data pelatihan untuk menghindari overfitting. Setelah pelatihan, model dievaluasi terhadap set pengujian untuk menilai performanya melalui confusion matrix dan classification report, yang menyediakan detail tentang precision, recall, f1-score, dan akurasi keseluruhan.

BAB IV

HASIL DAN PEMBAHASAN





Analisa Masalah

Dalam konteks klasifikasi tumor otak menggunakan metode Deep Learning CNN, terdapat beberapa masalah mendasar yang dihadapi, yaitu keterbatasan data yang berkualitas dan representatif, keragaman morfologis tumor otak yang memerlukan pengenalan pola-pola subtil, serta ketidakpastian dalam diagnosis awal yang dapat mempengaruhi kualitas label data untuk pelatihan model. Keterbatasan akses terhadap dataset yang besar dan beragam menjadi hambatan dalam pembangunan model yang akurat, sementara variasi jenis dan tingkat keparahan tumor memerlukan pendekatan yang sensitif terhadap perbedaan individu. Selain itu, tantangan dalam preprocessing data, seperti reduksi noise dan artefak, serta kebutuhan sumber daya komputasi yang besar untuk pelatihan model deep learning, juga menjadi kendala. Evaluasi model harus menggunakan metrik yang tepat untuk memberikan gambaran lengkap tentang kinerja model, termasuk akurasi, presisi, recall, dan F1-score.



Hasil Pemodelan

```
# Modelling CNN

input_shape = (128, 128, 1)

model = models.Sequential([
    layers.Conv2D(32, (3, 3), activation='relu', input_shape=input_shape),
    layers.MaxPooling2D((2, 2)),
    layers.Conv2D(64, (3, 3), activation='relu'),
    layers.MaxPooling2D((2, 2)),
    layers.Flatten(),
    layers.Dense(64, activation='relu'),
    layers.Dense(len(tumor_types), activation='softmax')
])

model.compile(optimizer='adam', loss='categorical_crossentropy', metrics=['accuracy'])
```


Modelling CNN:

- `input_shape = (128, 128, 1)`: Mendefinisikan bentuk input citra yang digunakan dalam model. Dalam hal ini, input citra memiliki resolusi 128x128 piksel dengan 1 kanal warna (grayscale).
- `models.Sequential([...])`: Membuat model sekuensial di mana lapisan-lapisan ditambahkan secara berurutan.

Lapisan Konvolusi 1:

- `layers.Conv2D(32, (3, 3), activation='relu', input_shape=input_shape)`: Lapisan konvolusi pertama dengan 32 filter ukuran 3x3 dan fungsi aktivasi ReLU. Lapisan ini menerima input citra dengan bentuk yang telah ditentukan.

Lapisan Pooling 1:

- `layers.MaxPooling2D((2, 2))`: Lapisan max pooling dengan ukuran pool 2x2 untuk mengurangi dimensi data.
- Lapisan Konvolusi 2:
- `layers.Conv2D(64, (3, 3), activation='relu')`: Lapisan konvolusi kedua dengan 64 filter ukuran 3x3 dan fungsi aktivasi ReLU.

Lapisan Pooling 2:

- `layers.MaxPooling2D((2, 2))`: Lapisan max pooling kedua dengan ukuran pool 2x2.
- `metrics=['accuracy']`: Menggunakan metrik akurasi untuk mengevaluasi performa model.

Lapisan Flatten:

- `layers.Flatten()`: Lapisan ini meratakan output dari lapisan konvolusi terakhir menjadi satu vektor satu dimensi.

Lapisan Dense 1:


- `layers.Dense(64, activation='relu')`: Lapisan fully connected dengan 64 neuron dan fungsi aktivasi ReLU.

Lapisan Dense 2:

- `layers.Dense(len(tumor_types), activation='softmax')`: Lapisan fully connected output dengan jumlah neuron yang sesuai dengan jumlah kelas tumor (dalam hal ini `len(tumor_types)`) dan fungsi aktivasi softmax untuk melakukan klasifikasi.

Kompilasi Model:

- `optimizer='adam'`: Menggunakan optimizer Adam untuk memperbarui bobot model selama pelatihan.
- `loss='categorical_crossentropy'`: Menggunakan fungsi loss categorical crossentropy yang cocok untuk masalah klasifikasi multi-kelas.



```
# Convert Label dengan one hot encoder  
label_encoder = LabelEncoder()  
train_labels_encoded = label_encoder.fit_transform(train_labels)  
test_labels_encoded = label_encoder.transform(test_labels)  
  
train_labels_one_hot = to_categorical(train_labels_encoded)  
test_labels_one_hot = to_categorical(test_labels_encoded)
```


- `label_encoder = LabelEncoder()`: Membuat instance dari `LabelEncoder` untuk mengubah label kategori menjadi numerik.
- `train_labels_encoded = label_encoder.fit_transform(train_labels)`: Mengubah label data pelatihan menjadi bentuk numerik.
- `test_labels_encoded = label_encoder.transform(test_labels)`: Mengubah label data pengujian menjadi bentuk numerik.
- `train_labels_one_hot = to_categorical(train_labels_encoded)`: Mengubah label data pelatihan yang sudah dalam bentuk numerik menjadi one-hot encoded.
- `test_labels_one_hot = to_categorical(test_labels_encoded)`: Mengubah label data pengujian yang sudah dalam bentuk numerik menjadi one-hot encoded.



Pembahasan Hasil

```
# Training Model
model.fit(train_images, train_labels_one_hot, epochs=10, batch_size=32, validation_split=0.2)

Epoch 1/10
62/62 [=====] - 58s 906ms/step - loss: 0.7938 - accuracy: 0.6524 - val_loss: 0.6229 - val_accu-
racy: 0.7297
Epoch 2/10
62/62 [=====] - 56s 908ms/step - loss: 0.6197 - accuracy: 0.7149 - val_loss: 0.5585 - val_accu-
racy: 0.7846
Epoch 3/10
62/62 [=====] - 50s 815ms/step - loss: 0.5106 - accuracy: 0.7754 - val_loss: 0.4776 - val_accu-
racy: 0.8313
Epoch 4/10
62/62 [=====] - 54s 868ms/step - loss: 0.4748 - accuracy: 0.8003 - val_loss: 0.5202 - val_accu-
racy: 0.7967
Epoch 5/10
62/62 [=====] - 53s 852ms/step - loss: 0.4083 - accuracy: 0.8313 - val_loss: 0.3889 - val_accu-
racy: 0.8415
Epoch 6/10
62/62 [=====] - 52s 829ms/step - loss: 0.3500 - accuracy: 0.8592 - val_loss: 0.3570 - val_accu-
racy: 0.8618
Epoch 7/10
62/62 [=====] - 52s 843ms/step - loss: 0.3114 - accuracy: 0.8730 - val_loss: 0.3663 - val_accu-
racy: 0.8618
Epoch 8/10
62/62 [=====] - 51s 833ms/step - loss: 0.2669 - accuracy: 0.8974 - val_loss: 0.2950 - val_accu-
racy: 0.8821
Epoch 9/10
62/62 [=====] - 53s 854ms/step - loss: 0.2313 - accuracy: 0.9111 - val_loss: 0.2909 - val_accu-
racy: 0.8801
Epoch 10/10
62/62 [=====] - 52s 841ms/step - loss: 0.1854 - accuracy: 0.9258 - val_loss: 0.2722 - val_accu-
racy: 0.9045
```




```
# Menghitung Confusion Matrix
cm = confusion_matrix(test_labels_encoded, test_labels_pred)
class_labels = ['glioma', 'meningioma', 'pituitary']

for i, label in enumerate(class_labels):
    TP = cm[i, i]
    FN = np.sum(cm[i, :]) - TP
    FP = np.sum(cm[:, i]) - TP
    TN = np.sum(cm) - TP - FN - FN

    true_positive_rate = TP / (TP + FN)
    true_negative_rate = TN / (TN + FP)
    false_positive_rate = FP / (FP + TN)
    false_negative_rate = FN / (FN + TP)

    print(f"Metrics for class '{label}':")
    print("True Positive:", TP)
    print("True Negative:", TN)
    print("False Positive:", FP)
    print("False Negative:", FN)
    print("True Positive Rate (Sensitivity):", true_positive_rate)
    print("True Negative Rate (Specificity):", true_negative_rate)
    print("False Positive Rate:", false_positive_rate)
    print("False Negative Rate:", false_negative_rate)
    print()

Metrics for class 'glioma':
True Positive: 103
True Negative: 441
False Positive: 32
False Negative: 39
True Positive Rate (Sensitivity): 0.7253521126760564
True Negative Rate (Specificity): 0.9323467230443975
False Positive Rate: 0.06765327695560254
False Negative Rate: 0.2746478873239437

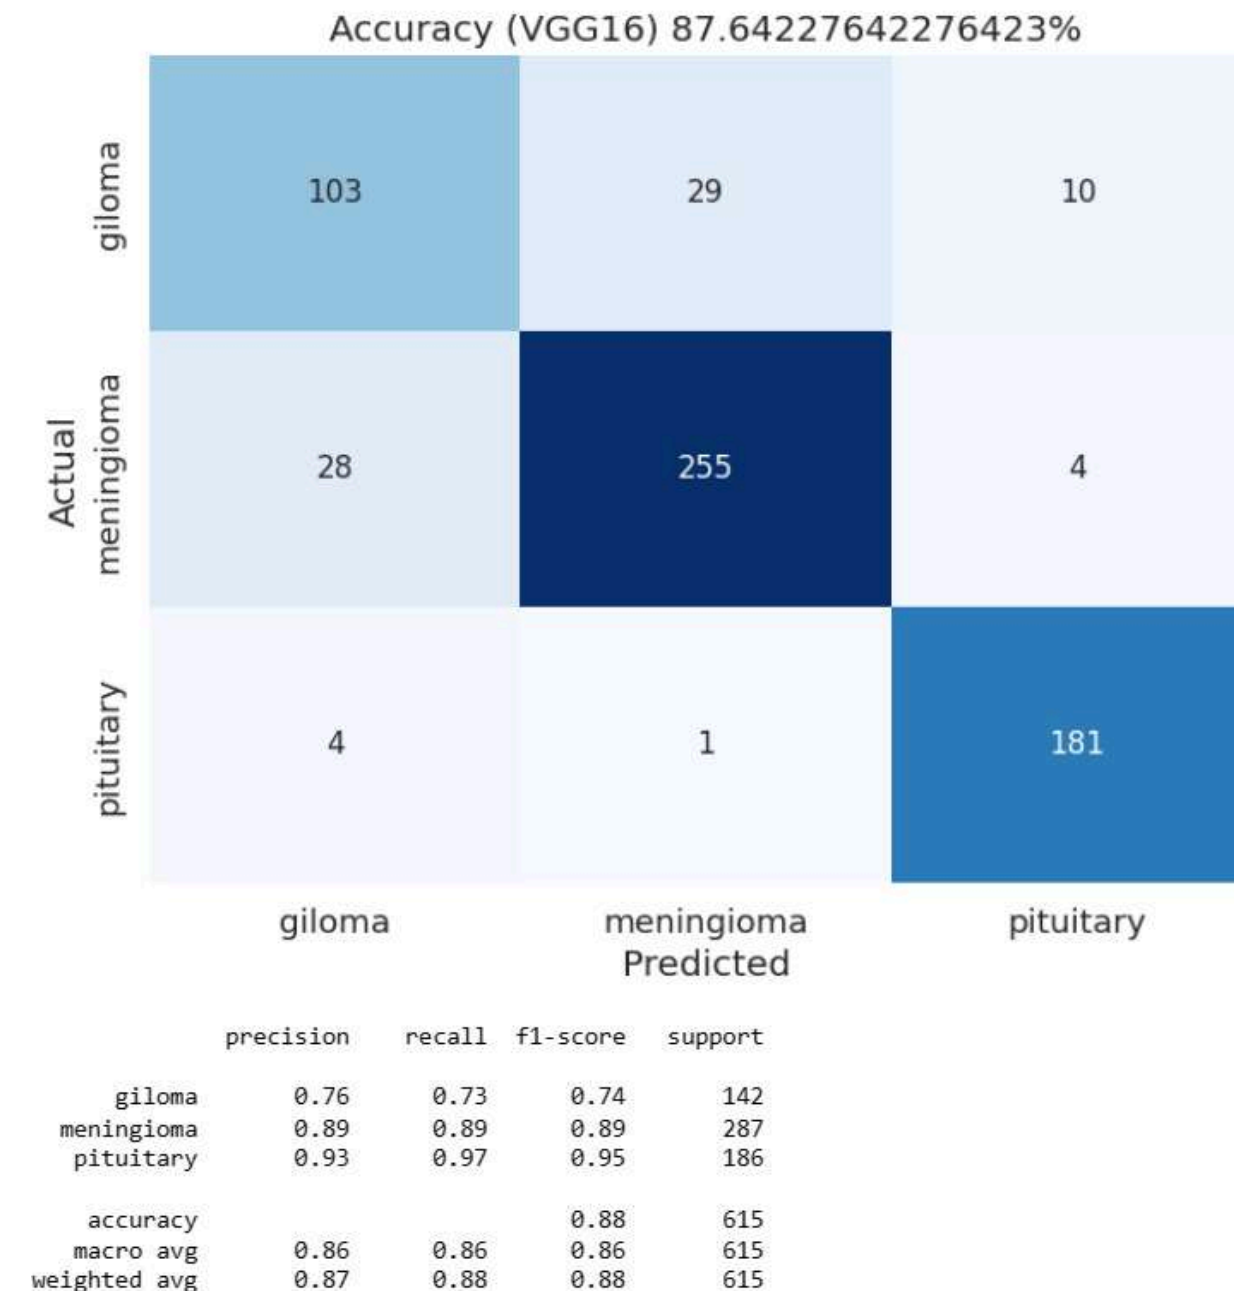
Metrics for class 'meningioma':
True Positive: 255
True Negative: 298
False Positive: 30
False Negative: 32
True Positive Rate (Sensitivity): 0.8885017421602788
True Negative Rate (Specificity): 0.9085365853658537
False Positive Rate: 0.09146341463414634
False Negative Rate: 0.11149825783972125

Metrics for class 'pituitary':
True Positive: 181
True Negative: 415
False Positive: 14
False Negative: 5
True Positive Rate (Sensitivity): 0.9731182795698925
True Negative Rate (Specificity): 0.9673659673659674
False Positive Rate: 0.03263403263403263
False Negative Rate: 0.026881720430107527
```

Confusion matrix untuk klasifikasi tumor otak menggunakan CNN dalam Deep Learning dalam penelitian ini menunjukkan matrix yang mendalam untuk tiga jenis tumor: glioma, meningioma, dan pituitary. Untuk glioma, model menunjukkan tingkat positif benar (sensitivitas) sebesar 0.7253 dan tingkat negatif benar (spesifisitas) sebesar 0.9323, mengindikasikan kemampuannya yang kuat untuk mengidentifikasi jenis tumor ini dengan benar sambil juga mengenali kasus non-glioma dengan tepat. Klasifikasi meningioma mencapai sensitivitas dan spesifisitas yang lebih tinggi, dengan tingkat masing-masing sebesar 0.8885 dan 0.9085, mencerminkan kekokohan model dalam membedakan tipe tumor ini. Model paling baik dalam mengklasifikasikan tumor pituitari, dengan sensitivitas yang mengesankan sebesar 0.9731 dan spesifisitas sebesar 0.9673, menegaskan presisi luar biasa untuk kategori ini. Matrix ini menunjukkan bahwa model CNN dalam Deep Learning dapat membedakan antara berbagai jenis tumor otak dengan efektif, menawarkan potensi besar untuk meningkatkan diagnosis dini dan perencanaan pengobatan.



Secara keseluruhan, heatmap confusion matrix menunjukkan akurasi model sebesar 87.64227642276423%, yang mengindikasikan efektivitas model dalam membedakan antara jenis-jenis tumor tersebut. Laporan klasifikasi di bawah heatmap mengonfirmasi tingkat presisi, recall, dan f1-score yang tinggi untuk setiap kategori, dengan rata-rata makro menunjukkan konsistensi performa yang kuat di semua kelas tumor



BAB V

SIMPULAN DAN SARAN





Kesimpulan

Berdasarkan hasil penelitian Klasifikasi Tumor Otak Menggunakan Metode Deep Learning CNN dapat disimpulkan bahwa pendekatan deep learning khususnya penggunaan CNN, memiliki efektivitas yang tinggi dalam mengklasifikasikan jenis-jenis tumor otak. Dengan mengintegrasikan teknik-teknik pemrosesan citra dan ekstraksi fitur otomatis, model yang dikembangkan mampu menghasilkan tingkat akurasi yang signifikan dalam mengidentifikasi glioma, meningioma, dan tumor pituitari. Heatmap confusion matrix menyediakan visualisasi yang jelas dari performa model, memperlihatkan kemampuan model untuk mengenali dan membedakan antara ketiga jenis tumor otak dengan presisi yang tinggi, yang didukung oleh metrik sensitivitas dan spesifisitas yang mengesankan.

Secara keseluruhan, penelitian ini memberikan bukti kuat bahwa teknologi deep learning khususnya CNN, dapat diandalkan sebagai alat bantu dalam proses diagnosis tumor otak.



Saran

Saran untuk penelitian selanjutnya adalah untuk melanjutkan penelitian dengan dataset yang lebih besar dan beragam. Dengan menggunakan dataset yang lebih luas, penelitian dapat memperkuat generalisasi model dan meningkatkan keakuratannya. Penggunaan beragam dataset juga penting untuk memastikan model dapat menangani variasi dalam citra medis yang mungkin ditemui dalam praktik klinis. Selain itu, pengembangan arsitektur model yang lebih canggih juga disarankan untuk meningkatkan efisiensi dan akurasi dalam klasifikasi tumor otak.

Daftar Pustaka

- [1] K. Amalia, R. Magladena, and S. Saidah, "Klasifikasi penyakit tumor otak pada citra MRI menggunakan metode CNN dengan arsitektur Alexnet," 2022, <https://openlibrarypublications.telkomuniversity.ac.id/index.php/engineering/article/view/18991>
- [2] L. O. Lukmana, "Deteksi tumor otak menggunakan CNN," *fikom-unasman.ac.id*, Oct. 2023, doi: 10.35329/jiik.v9i2.276.
- [3] G. Litjens et al., "A survey on deep learning in medical image analysis," in *Medical Image Analysis*, vol. 42, pp. 60–88, Dec. 2017. [Online]. Available: <https://doi.org/10.1016/j.media.2017.07.005>
- [4] A. Azhar, B. Siswoyo, D. Pratama, K. Anam, and H. Susana, "PENERAPAN ALGORITMA CONVOLUTIONAL NEURAL NETWORK (CNN) UNTUK DIAGNOSA TUMOR OTAK," *JATI*, vol. 8, no. 2, pp. 1797–1801, Apr. 2024, doi: 10.36040/jati.v8i2.8242.
- [5] D. Shen, G. Wu, and H.-I. Suk, "Deep Learning in Medical Image Analysis," in *Annual Review of Biomedical Engineering*, vol. 19, pp. 221–248, Jul. 2019. [Online]. Available: <https://doi.org/10.1146/annurev-bioeng-071516-044442>
- [6] "IMPLEMENTASI METODE CONVOLUTIONAL NEURAL NETWORK (CNN) DALAM MENDETEKSI JENIS SAMPAH – Repository UNJA," <https://repository.unja.ac.id/60591>
- [7] D. Gunawan and H. Setiawan, "Convolutional Neural Network dalam Citra Medis," *Konstelasi*, vol. 2, no. 2, May 2022, doi: 10.24002/konstelasi.v2i2.5367.
- [8] P. H. Trenggono and A. Bachtiar, "PERAN ARTIFICIAL INTELLIGENCE DALAM PELAYANAN KESEHATAN: A SYSTEMATIC REVIEW," *Jurnal Ners*, vol. 7, no. 1, pp. 444–451, Apr. 2023, doi: 10.31004/jn.v7i1.13612.
- [9] E. H. Rachmawanto, D. Hermanto, Z. Pratama, and C. A. Sari, "PERFORMA CONVOLUTIONAL NEURAL NETWORK DALAM DEEP LAYERS RESNET-50 UNTUK KLASIFIKASI MRI TUMOR OTAK," *SEMNAS RISTEK (Seminar Nasional Riset Dan Inovasi Teknologi)*, vol. 8, no. 01, Jan. 2024, doi: 10.30998/semnasristek.v8i01.7125.
- [10] N. Naf'iyah, "Identifikasi Tumor Otak Citra MRI dengan Convolutional Neural Network," *Jurnal Informatika/Jurnal Informatika: Jurnal Pengembangan IT*, vol. 8, no. 3, pp. 213–219, Sep. 2023, doi: 10.30591/jpit.v8i3.4985.
- [11] M. R. Khilmawan and A. A. Riadi, "IMPLEMENTASI PENGURANGAN NOISE PADA CITRA TULANG MENGGUNAKAN METODE MEDIAN FILTER DAN GAUSSIAN FILTER," *JUPI (Jurnal Ilmiah Penelitian Dan Pembelajaran Informatika)*, vol. 3, no. 2, Dec. 2018, doi: 10.29100/jupi.v3i2.865.
- [12] O. Ronneberger, P. Fischer, and T. Brox, "U-Net: Convolutional Networks for Biomedical Image Segmentation," in *Medical Image Computing and Computer-Assisted Intervention – MICCAI 2015*, 2015, doi: 10.1007/978-3-319-24574-4_28.
- [13] A. Esteva et al., "Dermatologist-level classification of skin cancer with deep neural networks," *Nature*, vol. 542, pp. 115–118, 2017, doi: 10.1038/nature21056.
- [14] H. R. Roth et al., "A new 2.5D representation for lymph node detection using random sets of deep convolutional neural network observations," in *Medical Image Computing and Computer-Assisted Intervention – MICCAI 2014*, 2014, doi: 10.1007/978-3-319-10470-6_58.
- [15] K. He et al., "Deep Residual Learning for Image Recognition," in *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2016, doi: 10.1109/CVPR.2016.90.
- [16] N. Pratama, M. Liebenlito, and Y. Irene, "Perbandingan Model Klasifikasi Transfer Learning Convolutional Neural Network Tumor Otak menggunakan Citra Magnetic Resonance Imaging," *Jurnal Sehat Indonesia (JUSINDO)*, vol. 6, no. 01, pp. 308–318, Jan. 2024, doi: 10.59141/jsi.v6i01.81.
- [17] M. Alizal, M. Susanto, A. Setyawan, H. Fitriawan, and M. Mardiana, "SISTEM KEAMANAN RUANGAN DENGAN HUMAN DETECTION MENGGUNAKAN SENSOR KAMERA BERBASIS DEEP LEARNING," *Alizal | Jurnal Teknoinfo*, Jan. 2024, doi: 10.33365/jti.v18i1.3798.
- [18] Z. M. Ilawanda and G. F. Atsani, "Gambaran Radiologis pada Bidang Neurologis Tumor Otak," *Jurnal Syntax Fusion*, vol. 1, no. 12, pp. 987–1001, Dec. 2021, doi: 10.54543/fusion.v1i12.125.



**THANK
YOU**